

Informatik

Geodatenprozessierung mit Budget Instanzen

Semesterarbeit



Abbildung 1: Eine Tour mit Budget Instanzen [Web10]

Departement:	Informatik
Kurs:	CAS CLD FS20 – Cloud Computing
Autor:	Tobias Reber
Experte:	Jörg Thomann
Ansprechpartner:	Christoph Böcklin
Datum:	23. 08. 2020

Perplexity
is the beginning of knowledge.

- Kahlil Gibran

[AD19, S. 33]

1 Management Summary

In der Kürze liegt die Würze

Inhaltsverzeichnis

1 Management Summary	ii
2 Einführung	1
2.1 GIS - Geographical Information Systems	1
3 Vorgehen	2
3.1 Arbeitsmethodik	2
3.2 Projektplan	2
4 Ausgangslage	3
4.1 swisstopo bei AWS	3
4.2 Publikation von Geodaten	3
4.3 Web-Services	3
4.4 Exkurs 3D Daten	4
5 Der Use Case	5
5.1 Problemstellung	5
5.1.1 Budget Instanzen	5
5.2 Ist-Zustand der 3D Datenpublikation	6
5.2.1 Prozess der Publikation	6
5.2.2 Aufwand der Prozessierung	7
5.2.3 Technische Komponenten	7
6 Architektur	8
6.1 Analyse des Ist-Zustandes	8
6.1.1 Bereitstellung der Rohdaten und Sicherstellung dessen Qualität	8
6.1.2 Bereitstellung der Infrastruktur für die Prozessierung	8
6.2 Bewertungskriterien	8
6.3 Architekturentscheid	8
6.3.1 Prozessierung auf Spot Instanzen	9
7 Prototyp	10
7.1 Realisierung	10
7.1.1 Der Publikationsprozess als Code	10
7.1.2 Handling der Interrupts	10
7.2 Testen	10
8 Evaluation	12
8.1 Erfahrungen	12
8.2 Wirtschaftlichkeit	12
8.3 Kritische Punkte	13
9 Ausblick	14
10 Schlusswort	14
Literaturverzeichnis	15
A Fachbegriffe und Abkürzungen	I
B Konfigurationen	II
C Kennenlernen von AWS	II

D Kanban	II
E Projektplan	III
F Konfigurationen und Kommandos	III
F.1 XML Testen	III
F.2 EFS auf EC2-Instanz mounten	V
F.3 Von der SPOT Instanz aus abfragen, was ihr Status ist	VII
G Für die Semesterarbeit verwendete Software	VIII

Abbildungsverzeichnis

1	Eine Tour mit Budget Instanzen [Web10]	1
2	Internetkarte des Bundes <i>map.geo.admin.ch</i> . Hier ein Ausschnitt der Saane bei Kleinbödingen, das Luftaufnahmen von 1946 mit heute vergleicht.	1
3	Im Viewer werden zurzeit Gebäude, Bäume, Seilbahnen, Namen und das Terrain dargestellt. Um aktuell zu bleiben, müssen diese 3D Daten regelmässig nachgeführt werden.	4
4	So funktioniert das Ausleihen von Budget (SPOT) Instanzen	5
5	Arbeitsschritte, die es braucht, um die 3D Daten zu Publizieren.	6
6	Geodatenprozessierung mit SPOT Instanzen	10
7	Klassisches Kanban auf <i>github.com</i>	II
8	Projektplan. Die orangen Meilensteine wurden von der BFH vorgegeben.	III

Tabellenverzeichnis

1	Relativ betrachtet ist das Sparpotential enorm: 76%	12
2	In der Arbeit verwendete Fachbegriffe und Abkürzungen	I

2 Einführung

Ich arbeite als GIS-Spezialist bei der swisstopo¹, dem Bundesamt für Landestopografie, in Wabern. Wir machen Karten. Unser Team macht Internetkarten - wie Google Maps², jedoch von der Schweiz für die Schweiz; und für alle anderen auch. Unsere Internetkarte, der Viewer, erfreut sich relativ grosser Beliebtheit und beinhaltet ca. 800 Themen wie Wanderwege, Solarkataster und Luftfahrthindernisse. Lieber Leser³, falls dir map.geo.admin.ch noch kein Begriff sein sollte, kann ich dir wärmstens empfehlen, darin zu schmökern. Es gibt viel zu entdecken und es ist gratis - ein Service Public.



Abbildung 2: Internetkarte des Bundes *map.geo.admin.ch*. Hier ein Ausschnitt der Saane bei Kleinbödingen, das Luftaufnahmen von 1946 mit heute vergleicht.

2.1 GIS - Geographical Information Systems

Wie erwähnt, arbeite ich als *GIS-Spezialist*. Wobei mir der Titel *Geo-Informatiker* besser gefällt: weil er die Begriffe *Geografie* und *Informatik* vereint. *Geografie* kommt aus dem Griechischen und bedeutet Erdbeschreibung [SE04, S. 14]. *Informatik* ist die Wissenschaft von der systematischen Darstellung, Speicherung, Verarbeitung und Übertragung von Informationen [10c].

GIS ist ein Akronym für Geographical Information Systems. Es bedeutet im engsten Sinn eine Ansammlung von Computerprogrammen, die zur Bearbeitung von Karten und Geodaten verwendet werden. Geodaten sind nichts weiter als Daten mit einem räumlichen Bezug⁴. In einem weiteren Sinn deckt der Begriff GIS ein ganzes Fachgebiet ab, das sich mit Karten und Geodaten auskennt. Es ist also nicht nur ein Werkzeug, sondern ein Fachgebiet, das Kenntnisse über Datensammlung, Speicherung, Analyse und Darstellung innerhalb von vielen verschiedenen Themen mit einem räumlichen Bezug abdeckt. Typische Geodaten sind digitale Karten, Inventare und Register von Parzellen, Umweltfaktoren, Grenzen, Entwicklung, Planung etc., die einen räumlichen Bezug haben und dadurch in einem geografischen Zusammenhang analysiert und dargestellt werden können [BJB06, S. 15].

Es ist zwar weit von der klassischen Geografie zu Zeiten Alexanders von Humboldt⁵ entfernt, aber es liegt auf der Hand, dass auch die Geografie Cloud Computing nutzt.

¹www.swisstopo.ch

²maps.google.com

³Im vorliegenden Dokument wird durchwegs der männliche Singular (Leser, Benutzer) als Ansprache verwendet. Diese Ansprache bezieht sich auf beide Geschlechter sowie gegebenenfalls mehrere Personen. Sie dient lediglich der leichteren Lesbarkeit der Semesterarbeit.

⁴Mit Koordinaten (Nord/Ost, x/y).

⁵Ein Forschungsreisender des 19. Jh. mit einem weit über Europa hinausreichenden Wirkungsfeld. Mehrjährige Forschungsreisen führten ihn nach Lateinamerika, USA und nach Zentralasien [Keh05].

3 Vorgehen

In diesem Kapitel wird das Vorgehen beschrieben, wie die Arbeit geplant und realisiert wurde.

3.1 Arbeitsmethodik

Da die Arbeit nur von einem Autor umgesetzt wurde, musste bezüglich Arbeitsmethodik nur wenig definiert und koordiniert werden.

Um zu starten, hat dem Autor geholfen, dass der Experte Jörg Thomann bereits anfangs Sommer (16. Juli) einen ersten Besprechungstermin angesetzt hat. Um eine Diskussionsbasis für diesen Termin zu haben, musste sich der Autor ernsthaft mit der Semesterarbeit auseinandersetzen. Dazu hat er aus einer BFH Vorlage ⁶ ein Gerüst der Arbeit erstellt und stichwortartig abgefüllt. Nach gründlicher Diskussion mit dem Experten wurde dieses Gerüst etwas angepasst und diente von da an als Basis für die Arbeit; wo sich die Kapitel zunehmend von losen Notizen zum finalen Zustand festigten.

Um die Übersicht nicht zu verlieren, wurde beschlossen, nach Kanban zu arbeiten, respektive ein Kanban Board zu verwenden. Weil für die Arbeit sowieso Repository auf github.com⁷ angelegt wurde, konnte dort auch gleich ein Kanban erstellt werden. Das Kanban Board wurde vor allem auch dafür genutzt, fortlaufend neue kleine Aufgaben aufzulisten und darauf zu achten, die Menge der angefangenen Arbeit zu begrenzen.

Dadurch konnte im Alltag (wenn gerade etwas Zeit zur Verfügung stand) eine solche Aufgabe genommen und erledigt werden. Es wurde nicht strikte nach Kanban gearbeitet, aber einige Prinzipien daraus wurden verwendet. Zum Beispiel wurde das erste Grundprinzip angewendet *"Beginne mit dem, was du gerade tust: In diesem Grundprinzip stecken zwei Dinge. Indem man mit dem beginnt, was man gerade tut, beendet man die aktuelle Arbeit, bevor etwas Neues begonnen wird. Genauso ist hier aber auch die Aussage enthalten, dass Kanban einfach eingeführt werden kann."*[10d]. Eine Momentaufnahme des Kanbans befindet sich im Anhang D.

3.2 Projektplan

Um den übergeordneten Rahmen der Arbeit nicht aus dem Fokus zu verlieren und um sich bewusst zu machen, wieviel Zeit generell bis zur Abgabe zur Verfügung steht, war es hilfreich, einen Projektplan mit Meilensteinen konsultieren zu können. Durch die Berner Fachhochschule waren die grundlegenden Meilensteine bereits vorgegeben. Der Projektplan befindet sich im Anhang E.

⁶Herzlichen Dank an Andreas Habegger und Lukas Studer fürs Bereitstellen der Vorlage

⁷Projekt auf github.com

4 Ausgangslage

Hier werden das Arbeitsumfeld und die Aufgaben beschrieben, aus denen sich die Problemstellung dieser Semesterarbeit ergeben hat.

4.1 swisstopo bei AWS

Es liegt auf der Hand, dass die swisstopo in ihrer Rolle als *Geoinformationszentrum* auf Cloud Computing setzt. Die swisstopo nutzt Cloud Computing mit AWS⁸ seit mehr als 10 Jahren für den Betrieb des Geoportal des Bundes.

"Mit der BGD⁹ unter AWS können wir derzeit ca. eine Million Internetbenutzer pro Monat bedienen. Dank AWS können wir die zur Zuordnung neuer Server benötigte Zeit erheblich verkürzen und unseren Fokus auf echte Kundenanforderungen verstärken." [Chr20].

4.2 Publikation von Geodaten

Wie bereits erwähnt, können auf dem Viewer ca. 800 Themen wie Wanderwege, Solarkataster und Luftfahrthindernisse angesehen werden. Unser Team publiziert diese Daten. Der Nachführungszyklus wie auch der Aufwand zur Aufbereitung der Daten fürs Web sind unterschiedlich. Einige Daten werden manuell aufwändig aufbereitet, andere stündlich automatisch nachgeführt.

4.3 Web-Services

Nebst der Publikation der Daten ist unser Team für den Betrieb und der Weiterentwicklung der Web-Services und des Viewers verantwortlich. Der ganze Technologie Stack wurde schon länger nicht mehr grundlegend erneuert. Zurzeit wird die gesamte Architektur analysiert und überarbeitet, um eine gestaffelte Migration auf eine neue Lösung zu ermöglichen. Einige Rahmenbedingungen dieser zukünftigen Architektur sind bereits klar: Das Geoportal des Bundes wird weiterhin in der AWS Cloud betrieben werden, die Migration wird vor allem über Microservices gestaffelt erfolgen, diese Services werden als Docker Container laufen, Amazon Elastic Kubernetes Service wird die Orchestrierung der Container übernehmen; und für Continuous Integration wird AWS Codebuild/Pipeline zum Einsatz kommen.

⁸Amazon Web Services

⁹Bundesgeodateninfrastruktur: Viewer und andere Services.

4.4 Exkurs 3D Daten

Die swisstopo erfasst und aktualisiert Daten mit einem räumlichen Bezug. Diese Geodaten sind die Basis für die Ableitung in eine Vielzahl von Produkten, wie die Landeskarten 1:25'000. Nebst Karten gibt es die Produktpalette der Landschaftsmodelle. Diese geben die Objekte der Landschaft im flexiblen Vektorformat wieder. Sie bestehen aus thematischen Ebenen (Bsp. Gebäude). Jede Ebene umfasst georeferenzierte Punkt-, Linien-, Flächen- oder 3D-Objekte. Jedes Objekt enthält Attribute und Beziehungen [10e].

Zu den Landschaftsmodellen gehören Produkte wie swissTLM3D und swissBuildings3D. Im Viewer wird eine Auswahl von Themen aus eben diesen Landschaftsmodellen dargestellt: Zurzeit Gebäude, Bäume, Seilbahnen, Namen und das Terrain. Vor wenigen Jahren wurden diese 3D Daten mit einem grossen Effort medienwirksam publiziert.




Abbildung 3: Im Viewer werden zurzeit Gebäude, Bäume, Seilbahnen, Namen und das Terrain dargestellt. Um aktuell zu bleiben, müssen diese 3D Daten regelmässig nachgeführt werden.

Seit der Erstpublikation ist inzwischen etwas Zeit vergangen. Als die ersten Aktualisierungen der Daten anstanden, wurde den Beteiligten bewusst, dass sich diese nicht einfach so *auf Knopfdruck* realisieren lässt: Seit der Erstpublikation hat es personelle Wechsel gegeben und punkto Dokumentation und Automatisierungsgrad wurden Lücken identifiziert.

Es gibt immer gute Gründe für *technische Schulden*, wie in diesem Fall für positive medienwirksame Reaktionen¹⁰. Früher oder später müssen diese abgebaut werden, weil es einen direkten Einfluss auf die Wartbarkeit des Produktes hat [10f].

¹⁰Wie Bsp. auf watson.ch oder Twitter [18]

5 Der Use Case

5.1 Problemstellung

Es ist der swisstopo schon lange ein Anliegen, dass die Publikationsprozesse von Geodaten optimiert werden sollen. Wann immer möglich, soll der Automatisierungsgrad erhöht werden.

Besonders aufwändig erweist sich zurzeit die Publikation von 3D Daten. Die manuelle Publikation der 3D Daten benötigt eigene Tools, die auf einem performanten und somit teuren Rechner laufen müssen. Ausserdem erfordert die Bereitstellung einen hohen Koordinationsaufwand zwischen der Infrastruktur und der Entwicklung. Dabei passiert es, dass Mängel in den 3D Daten erst nach beendeter Webpublikation bemerkt werden; und der ganze Publikationsprozess muss wieder von vorne gestartet werden. Auch dem Hersteller der 3D Daten (dem Bereich Topografie) wäre es ein Anliegen, wenn er diese Daten selbst automatisch publizieren und prüfen könnte.

Einerseits soll in dieser Arbeit mittels POC¹¹ aufgezeigt werden, wie der Automatisierungsgrad erhöht werden könnte. Andererseits soll untersucht werden, ob für die Prozessierung Budget Instanzen¹² anstelle von On-Demand Instanzen¹³ verwendet werden können und wie deren Einsatz aussehen könnte.

5.1.1 Budget Instanzen

Amazon preist Budget Instanzen folgendermassen an: *"Mit Amazon EC2 Spot-Instances können Sie die Vorteile nicht genutzter EC2-Kapazitäten in der AWS Cloud nutzen. Spot-Instances sind mit einem Rabatt von bis zu 90 % im Vergleich zum On-Demand-Preis verfügbar. Sie können Spot-Instances für diverse statuslose, fehlertolerante und flexible Anwendungen verwenden. Dazu zählen unter anderem Big-Data-Anwendungen, auf Containern ausgeführte Workloads, CI/CD, Webserver-Anwendungen, HPC-Anwendungen (High-Performance Computing) sowie Test- und Entwicklungs-Workloads."* [10a].

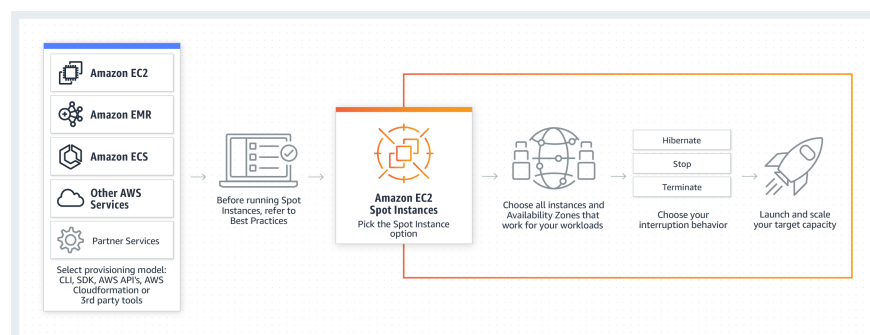


Abbildung 4: So funktioniert das Ausleihen von Budget (SPOT) Instanzen

Das Verkaufsargument 90 % Rabatt ist eine Ansage: Eine Preis-Aktion, ein Budget Produkt, damit AWS nicht genutzte EC2-Kapazitäten doch noch verkaufen kann. Der Konsument gibt viel weniger aus, mit dem Hacken, dass einem die Instanz innerhalb von 2 minütiger Vorankündigung weggenommen werden kann.

Möchte man die EC2 Spot Instanzen für Geodatenprozessierung einsetzen, muss also ein Weg gefunden werden, um mit diesen Unterbrüchen umgehen zu können.

Wie auf der Abbildung 4 dargestellt, kann das Verhalten der Instanz bei einem Interrupt¹⁴ definiert werden. Es

¹¹Prove of Concept

¹²Amazon Spot Instanzen

¹³Herkömmliche EC2 Instanzen.

¹⁴Wenn Amazon die Spot Instanz für einen anderen Zweck beanspruchen möchte, die wegnimmt.

besteht dabei sogar die Möglichkeit eines *Hibernate*, dass der Zustand des RAMs auf der Festplatte persistiert wird.

Diese 2 minütige Vorankündigung eines Interrupts kann auch via RESTful Abfrage¹⁵ von der Instanz aus abgefragt werden.

Diese Vorankündigung lässt sich auch via AWS CLI abfragen. In einem grösseren Setup könnte das Signal der Vorankündigung auch mit dem AWS Überwachungstool *CloudWatch* verarbeitet werden.

5.2 Ist-Zustand der 3D Datenpublikation

5.2.1 Prozess der Publikation

Das Aufzeigen des Ist-Zustandes der 3D Datenpublikation soll helfen sich einen Überblick, eine Ausgangslage, zu verschaffen. Es bildet die Grundlage, um die Frage zu beantworten, welche Arbeiten erledigt werden müssen, um die 3D Daten im Web zu publizieren? Welche Arbeitsschritte könnten automatisiert werden?

Eine Datenpublikation läuft folgendermassen ab: Sobald der Auftrag für eine 3D Datenpublikation erteilt wurde¹⁶, müssen zurzeit folgende Schritte, die in der Abbildung 6 referenziert sind, erledigt werden:




Abbildung 5: Arbeitsschritte, die es braucht, um die 3D Daten zu Publizieren.

1. Die Rohdaten¹⁷ werden vom Auftraggeber (Bereich Topografie) auf einem NAS bereitgestellt.
2. Da es sich um Millionen Dateien handelt, werden diese je Kartenblatt erst einmal gezippt, um so (weil bedeutend weniger Dateien) schneller kopiert werden zu können.
3. Kopieren der gezippten Dateien vom swisstopo Netzwerk in die Amazon Cloud (AWS VPC¹⁸) kopiert¹⁹
4. Parallel dazu wird die IT via Ticket gebeten einen Server mit dem entsprechenden Image²⁰ bereitzustellen.
5. Kopieren und Entzippen der Rohdaten auf die gemountete Festplatte²¹ des Servers.
6. Die Daten auf dem Server via Docker prozessieren²².
7. Kopieren der Web-optimierten Daten auf S3.

¹⁵EC2 Spot Instance Interruption Notice, eine HTTP Abfrage: Im Anhang F.3 hat es ein Beispiel dazu.

¹⁶Vom Bereich Topografie

¹⁷Das Format der Rohdaten ist KML/COLLADA

¹⁸AWS: Amazon Web Services, VPC: Virtual Private Network. Ein Kopieren

¹⁹Via *rsync*

²⁰Eine EC2 Instanz *eine m4.10xlarge* aus einem bereits vorhandenes AMI

²¹Ein EBS Volume

²²Umwandeln ist das Web-Format *Cesium3DTiles*

8. Die Daten visualisieren, um inhaltlich testen zu können. Ein Codepen Projekt²³, dass auf die 3D Tiles zugreift.

5.2.2 Aufwand der Prozessierung

Folgende Schritte sind besonders aufwendig:

- ▶ **Abb. 6, Schritt 2. und 5.:** Das Kopieren / Zippen (Packen und Entpacken) der Rohdaten nimmt lange.
- ▶ Es kommt immer mal wieder vor, dass Daten korrupt sind, was zu einer Nachlieferung führt, mit der Gefahr, dass es mit Versionen der Lieferung zu einem Durcheinander kommen könnte.
- ▶ **Abb. 6, Schritt 4.:** Unsere IT muss für die Prozessierung eine EC2 Instanz mit EFS bereitzustellen. Um laufende Kosten zu verringern, wird diese Instanz nach getaner Arbeit²⁴ wieder gestoppt. Falls mit den Daten etwas nicht in Ordnung ist, muss dieser Schritt von der IT wiederholt werden. Nebst der Bemühung der IT, muss auf der Instanz selber anschliessend das eine und andere manuell installiert und konfiguriert werden.

5.2.3 Technische Komponenten

Auflistung der technischen Komponenten:

- ▶ **Abb. 6, Schritt 2., 3. und 5.:** Das Komprimieren und Kopieren der Rohdaten erfolgt mit Linux Bordmitteln (*cp, rsync, tar*)
- ▶ **Abb. 6, Schritt 4. und 7.:** Erfolgen via AWS CLI
- ▶ **Abb. 6, Schritt 6.:** Via Docker. Der Container wurde von der Firma Analytical Graphics Inc. [10b] bereitgestellt. Das Tool, das die Rohdaten in ein Web-Format umwandelt, wird mit Node.js ausgeführt.
- ▶ **Abb. 6, Schritt 7.:** Ein Projekt, um die Daten im Browser betrachten und inhaltlich Testen zu können, erfolgt über die Webseite codepen.io.

²³SaaS: Eine Webseite, um Front-End Code zu schreiben, zu testen, und bereitzustellen (codepen.io)

²⁴Der Prozessierung

6 Architektur

6.1 Analyse des Ist-Zustandes

6.1.1 Bereitstellung der Rohdaten und Sicherstellung dessen Qualität

Basierend auf der Aufwandeinschätzung des Ist-Zustandes des Kapitels 5.2.2 geht hervor, dass vor allem das Bereitstellen der Rohdaten und das Sicherstellen dessen Qualität aufwändig ist.

Das Bereitstellen der Rohdaten nimmt aufgrund der Datenmenge²⁵ viel Zeit in Anspruch. Hier gäbe es folgende zwei Lösungsansätze:

1. Der Datenlieferant könnte direkt aufs EFS schreiben (Abb. 6, Nr. 5)
2. Automatischer Prozess via Cronjob oder oder Trigger, der die Kopier-Schritte (Abb. 6, Schritte Abb. 6) regelmässig bereitstellt.

Wobei der Lösungsansatz simpler und somit weniger fehleranfällig zu sein scheint. Dieser Ansatz kann, sobald die swisstopo eine Hybrid Cloud hat, weiterverfolgt werden.

Sicherung der Qualität: Weil es dem Lieferanten an Tools fehlt, um die bereitgestellten Daten inhaltlich zu Prüfen, werden Fehler häufig erst nach der Publikation entdeckt. Dies sicherlich auch, weil die Daten im Web an ein breites Publikum gelangen. Da keine inhaltliche Prüfung der Daten gemacht werden kann, könnte man sich überlegen, wie die Daten sonst noch geprüft werden könnten.

6.1.2 Bereitstellung der Infrastruktur für die Prozessierung

Die Rohdaten werden via Docker Image prozessiert. Jedes Mal wenn das Image fürs Prozessieren ausgeführt werden soll, muss die IT gebeten werden die nötige Infrastruktur bereitzustellen. Idealerweise findet sich eine Lösung, die diesen Schritt überflüssig macht.

6.2 Bewertungskriterien

Kosten einsparen	Änderungen des Prozesses sollen nicht teurer sein, als die bisherige Lösung
Automatisierbar	Die Lösung soll den Grad der Automatisierung möglichst weit vorantreiben und dadurch so wenig Personalaufwand wie möglich beanspruchen.
Einfach	Ein neuer Mitarbeiter soll die Lösung rasch verstehen und warten können.
Bestehende Technologie	Obwohl der Anwendungsfall anders ist, soll der Technologie Stack möglichst demjenigen der Microservices entsprechen.

6.3 Architekturentscheid

Für den Architekturentscheid wurde auf eine Entscheidungsmatrix verzichtet. Dies Aufgrund der grossen Auswahl und der vielen Entscheidungen, die getroffen werden mussten. Die oben erwähnten Kriterien wurden in der

²⁵Weil es sich um mehrere Millionen Dateien handelt

Entscheidungsfindung mit einbezogen und weitere Argumente werden ausgeführt:

6.3.1 Prozessierung auf Spot Instanzen

Um Geodaten mit AWS Spot Instanzen zu prozessieren, hat der Autor drei Möglichkeiten identifiziert: *Direkt auf der Spot Instanz*, *Kubernetes (EKS)* und *AWS Batch*. Gerne hätte der Autor alle drei Lösungen als POC weiterverfolgt, aber die Zeit dazu reichte leider nicht. Aus diesem Grund beschränkt sich der Autor lediglich auf eine Beschreibung der drei Möglichkeiten. Wobei die erste Möglichkeit als POC umgesetzt wurde.

Direkt auf einer Spot Instanz: Diese Möglichkeit bedingt nur geringe Anpassungen der bisherigen Prozessierung, weil die Daten im Prinzip wie bisher auf EC2 Instanz prozessiert werden; mit dem Nachteil, dass diese jederzeit durch eine andere Instanz ersetzt werden könnte.

Der Autor hat sich bei der Auswahl der Images²⁶ für *Ubuntu Server 18.04 LTS* entschieden. Dies weil das Processing bisher auf Ubuntu gelaufen ist und weil er keinen Grund sieht, etwas das funktioniert zu ändern. Dasselbe Argument gilt für die Wahl der Dimensionierung des Servers: Ein Server mit 200 GB SSD Festplatte, 16 CPUs und 60 GByte Arbeitsspeicher konnte die Prozessierung der 3D Daten²⁷ gut stemmen.

Bei der Provisionierung²⁸ des Servers wurde der *"Cloud-init"* Ansatz gewählt: Dieser Ansatz richtet das Ubuntu Image in der Startup Phase des Servers ein. Dies hat gegenüber einem eigenen AMI den Vorteil, dass die Spezialisierung²⁹ in einer Textdatei festgehalten wird und somit jederzeit nachvollziehbar ist. Ausserdem muss bei einem Update des Basis Images kein neues Image gebaut werden. Die Initialisierungsskript wurde auf ein Minimum beschränkt und die eigentliche Initialisierung wurde an *Ansible* übergeben.

Kubernetes (EKS) auf Spot Instanzen erweitern TODO: Weil die Microservices in Zukunft auf EKS laufen werden, wäre es sicher ein Möglichkeit, abzuklären, inwiefern sich ein Dataprocessing in dieser Umgebung einrichten lässt. In der Literatur hat der Autor folgende Elemente gefunden.

- ▶ Job
- ▶ CronJob
- ▶ Eigenes ReplicaSet?

EBook auf meinem Reader: Job und CronJob aber auch Kubernetes on AWS S. 88

AWS Batch auf Spot Instanzen Diese Möglichkeit wäre wohl die Naheliegendste, weil AWS Batch für genau diese Art von Aufgaben gebaut wurde. Im Internet hat der Autor ein schönes Beispiel gefunden, wie sich AWS Batch einsetzen lässt. <https://aws.amazon.com/de/blogs/compute/creating-a-simple-fetch-and-run-aws-batch-job/>

²⁶ AMI: Amazon Machine Image.

²⁷ Gebäude, Bäume und Namen.

²⁸ Bereitstellung

²⁹ Das Einrichten.

7 Prototyp

7.1 Realisierung

Für die Realisierung des Prototypen hat der Autor das Kennenlern-Angebot von AWS, ein einjähriges kostenloses Kontingent an Services und Produkten[20], gewählt.

Nachdem der *AWS Testaccount* erstellt war, mussten erste Schritte wie grundlegende Konfigurationen des Identity Access Management (IAM) gemacht und das Steuern von Spot Anfragen erlernt werden.

Weitere Schritte folgten. Die Realisierung des Prototypen wird in den folgenden Kapiteln beschrieben werden.

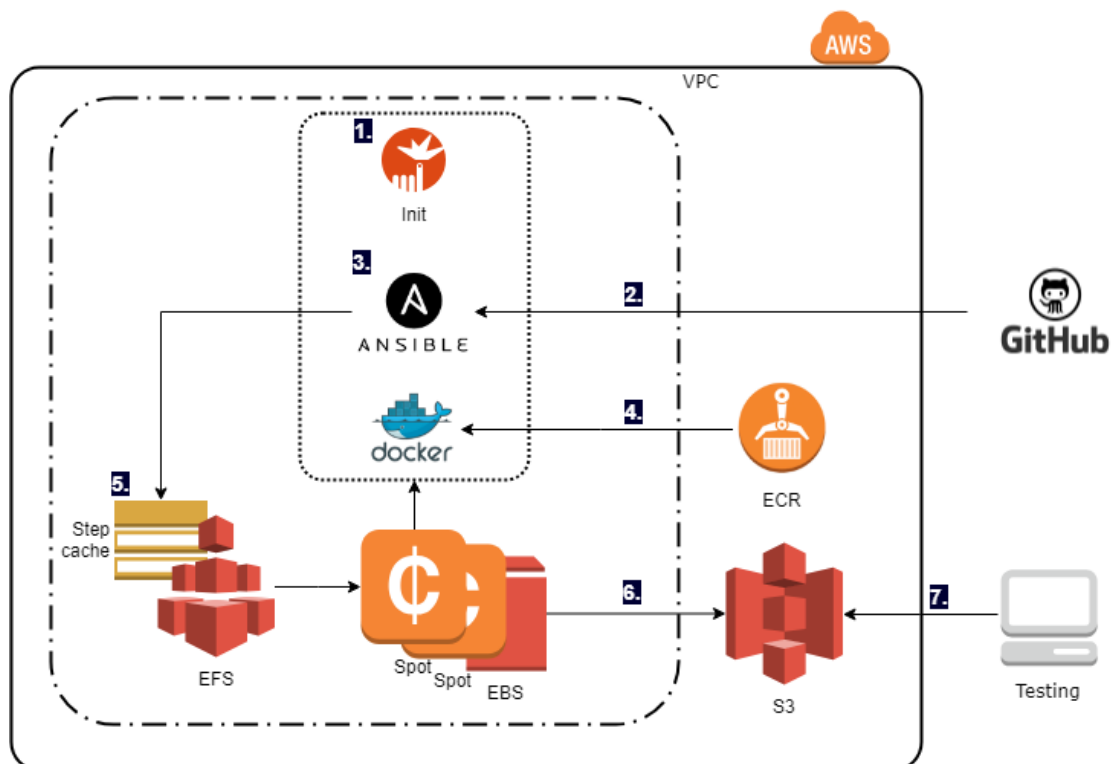


Abbildung 6: Geodatenprozessierung mit SPOT Instanzen

7.1.1 Der Publikationsprozess als Code

Aus der Abbildung 6 ist ersichtlich, dass Ansible eine zentrale Rolle im Publikationsprozess einnimmt.

7.1.2 Handling der Interrupts

7.2 Testen

Testen der Datenstruktur

Unerwartetes Herunterfahren

Real Case Szenario Der komplette Rohdatensatz, alle Gebäude der Schweiz, wurde prozessiert. Das Resultat kann vorläufig³⁰ hier betrachtet werden: <https://codepen.io/rebert/pen/ExKZmmE> Wobei nur die Gebäude vom S3 Testbucket kommen.

³⁰Bis am 1. November 2020

8 Evaluation

8.1 Erfahrungen

Die Anregungen aus dem Studium³¹ und das günstige Angebot von AWS haben den Autor motiviert, die komplette Infrastruktur für den Prototypen selber in einem eigenen AWS Testaccount aufzubauen. Da die Infrastruktur und das Processing deklarativ festgehalten wurden, kann ein Grossteil dieses Codes auch im Account des Betriebes ohne grosse Anpassungen wiederverwendet werden.

Im Betrieb hätte das Team und die IT Abteilung das nötige Know-How gehabt, um mit dieser Arbeit weiter zu kommen, als es jetzt der Fall ist. Aber der Autor hat sich bewusst dazu entschieden, die Arbeit möglichst selbständig zu realisieren und diese Ressource zu schonen, indem er sie so wenig wie möglich genutzt hat. Es war für den Autor schon nur eine Hilfe, zu Wissen, dass die Möglichkeit einer Unterstützung da war. Dies führte dazu, dass der Autor Momente der Ratlosigkeit erleben musste. Was nicht weiter schlimm war, da *"Perplexity is the beginning of knowledge"* [AD19, S. 33].

Bei der Auswahl der Spot-Instanz Aufgabe hat der Autor *Flexible Workloads* gewählt. Aufgrund der gemounteten SSD Festplatte musste der Pool der freien Instanzen auf die Availability-Zone, in welcher sich die Festplatte befindet, eingeschränkt werden. Der Autor war darüber erstaunt, dass ihm während der ganzen Entwicklungs- und Testphase nicht ein einziges Mal eine Instanz weggenommen wurde; dies trotz Beschränkung auf eine Availability-Zone.

8.2 Wirtschaftlichkeit

Personalstunden Der Grad der Automatisierung konnte erheblich erhöht werden. Dadurch fallen Personalstunden³² weg. Vor allem diese Kosten rechnen sich. Die Prozessierungsschritte sind im Code abgebildet, was Fehleranfälligkeit kleiner macht, als wenn Bash-Befehle aus der Prozessdokumentation kopiert werden müssen. Um die IT Abteilung gänzlich zu Entlasten, müsste noch eine Rolle³³ eingerichtet werden, die eine vordefinierte Spot Flottenanfrage steuern kann.

Einsparungen Spot im Vergleich zu On-Demand Um die Kosten von On-Demand mit Spot Instanzen zu vergleichen, werden hier die Ergebnisse des POCs aufgelistet. Prozessierung der Gebäude mit der Mindestanforderung: 16 CPUs und 60 GByte Memory. Die Gesamtrechnenzeit war ca. 18 Stunden und es konnten 76% der Kosten eingespart werden.

Rechenzeit	On-Demand	Spot
Pro Stunde	0.29 \$	1.19 \$
Total: 18 h	21.42 \$	5.22 \$

Tabelle 1: Relativ betrachtet ist das Sparpotential enorm: 76%

Schaut man die Kosten relativ an, dann ist das Sparpotential enorm: 76%! In absoluten Zahlen erscheint das Sparpotential für einen einzelnen Prozessierungsauftrag nicht riesig: ca. 15 \$. Dazu muss allerdings ergänzt werden, dass die Prozessierungszeit durch die Automatisierung verkürzt wurde. Ausserdem werden jährlich mehrere 3D Updates in Auftrag gegeben. Der grösste davon ist das Update des 3D Terrains.

³¹CAS in Cloud Computing an der BFH Bern: Bsp. die Vorlesungen Architektur, IaaS, PaaS, Docker und Kubernetes

³²In unserem Team

³³In der AWS eine sogenannter IAM-Benutzer

8.3 Kritische Punkte

TODO: Bezüglich Authentifizierung hat der POC Technische Schulden.

Schön wäre, wenn der Prozess selber in viele kleine Teile aufgeteilt werden könnte. Doch zurzeit ist das Tool eine einzige Backbox in einem Container und es funktionieren nur vollständige Publikationen und keine Inkrementellen.

9 Ausblick

10 Schlusswort

Literaturverzeichnis

- [10a] (2010). Amazon EC2-Spot-Instances, Adresse: <https://aws.amazon.com/de/ec2/spot/> (besucht am 08.07.2010).
- [10b] (2010). Analytical Graphics Inc., Adresse: <https://www.agi.com> (besucht am 09.08.2020).
- [10c] (2010). Informatik, Adresse: <https://de.wikipedia.org/wiki/Informatik> (besucht am 16.07.2010).
- [10d] (2010). Kanban (Softwareentwicklung), Adresse: [https://de.wikipedia.org/wiki/Kanban_\(Softwareentwicklung\)](https://de.wikipedia.org/wiki/Kanban_(Softwareentwicklung)) (besucht am 19.07.2010).
- [10e] (2010). swisstopo Onlineshop, Adresse: <https://shop.swisstopo.admin.ch> (besucht am 17.07.2020).
- [10f] (2010). Technische Schulden, Adresse: https://de.wikipedia.org/wiki/Technische_Schulden (besucht am 18.07.2010).
- [18] (2018). Diese 3D-Landkarte gibt dir einen völlig neuen Blick auf die Schweiz, Adresse: <https://www.watson.ch/digital/schweiz/674619561-diese-3d-landkarte-gibt-dir-einen-voellig-neuen-blick-auf-die-schweiz> (besucht am 18.07.2010).
- [20] (2020). AWS Free Tier, Adresse: <https://aws.amazon.com/de/free/?all-free-tier.sort-by=item.additionalFields.SortRank&all-free-tier.sort-order=asc> (besucht am 21.08.2020).
- [AD19] J. Arundel und J. Domingus, *Cloud Native DevOps with Kubernetes*. O'RELLY, 2019.
- [BJB06] T. Balstrøm, O. Jacobi und L. Bodum, *GIS og geodata*. Forlaget GIS og Geodata, 2006.
- [Chr20] H. Christ. (9. Juli 2020). swisstopo Fallstudie, Adresse: <https://aws.amazon.com/de/solutions/case-studies/swisstopo-hpc/>.
- [Keh05] D. Kehlmann, *Die Vermessung der Welt*. Rowohlt Verlag GmbH, 23. Sep. 2005, 304 S., ISBN: 3498035282. Adresse: https://www.ebook.de/de/product/3563778/daniel_kehlmann_die_vermessung_der_welt.html.
- [SE04] M.-H. Schertenleib und H. Egli-Broz, *Grundlagen Geografie: Aufgaben des Fachs, Erde als Himmelskörper und Kartografie : Lerntext, Aufgaben mit Lösungen und Kurztheorie*. Zürich: Compendio Bildungsmedien, 2004, ISBN: 3715591714.
- [Web10] Webpage. (2010). Keep calm and make your choice..., Adresse: <https://www.grenke-40-one.de/excursions-detail/> (besucht am 11.07.2010).

A Fachbegriffe und Abkürzungen

Abkürzung	Definition
Ansible	Ein Open-Source Automatisierungs-Werkzeug zur Orchestrierung und allgemeinen Konfiguration und Administration von Computern.
AMI	Amazon Machine Images: Images für virtuelle Server.
Availability Zone	Jeder Amazon Rechenzentrumstandort (Region) besteht aus mehreren isolierten Zonen, den Availability Zones.
AWS	Amazon Web Services.
AWS CLI	Das Command Line Interface, um AWS Ressourcen zu verwalten.
BGDI	Bundesgeodateninfrastruktur.
Budget Instanzen	Im Kontext dieser Arbeit ein Synonym für AWS Spot Instanzen.
EBS	Block Storage: Speicher (für eine Instanz).
EC2	Amazon Elastic Compute Cloud: Rechenkapazität, Speicher (und mehr).
EFS	Amazon Elastic File System: Cloud NFS-Dateisystem.
Hybrid Cloud	Eine Computerinfrastruktur, die Public Cloud und Private Cloud kombiniert nutzt.
IaaS	Cloud Infrastructure as a Service: Infrastruktur <i>"Pay as you go"</i> beziehen.
IAM	Identity and Access Management: Verwaltung der Zugänge und der dazugehörenden Rechte.
On-Demand Instanzen	Herkömmliche EC2 Instanzen. Der Begriff wird in dieser Arbeit manchmal verwendet, um von EC2 Spot Instanzen unterscheiden zu können.
PaaS	Plattform as a Service.
POC	Proof of Concept: Die Machbarkeit eines Produktes oder einer Idee aufzeigen.
S3	Amazon S3 (Simple Storage Service): Ein Filehosting-Dienst dessen Zugriff über HTTP/HTTPS erfolgt.
SaaS	Software as a Service.
SSD	Solid-State-Disk - Halbleiterlaufwerk: Festplatte ohne bewegliche Teile, dafür mit kurzen Zugriffszeiten.
S3	Simple Storage Service: Ein Objektspeicherservice von Amazon.

Tabelle 2: In der Arbeit verwendete Fachbegriffe und Abkürzungen

B Konfigurationen

C Kennenlernen von AWS

D Kanban




Abbildung 7: Klassisches Kanban auf *github.com*

E Projektplan

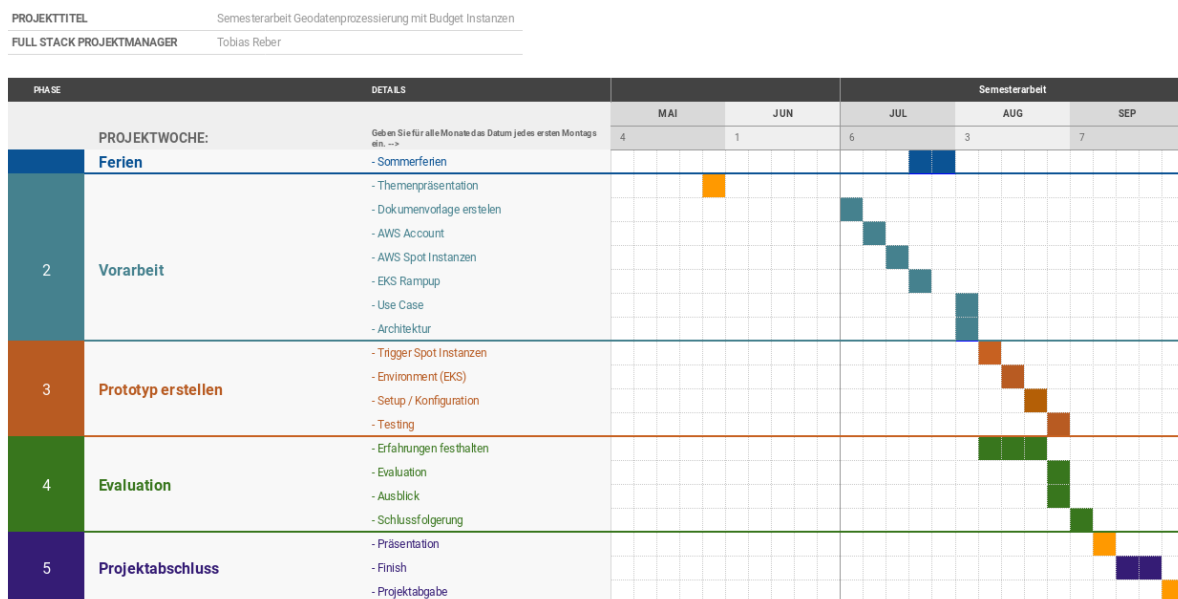


Abbildung 8: Projektplan. Die orangenen Meilensteine wurden von der BFH vorgegeben.

F Konfigurationen und Kommandos

F.1 XML Testen

Einfaches Skript, um zu testen, ob alle XML-Dateien well-formed sind.

Listing 1: XML testen

```
import os
from lxml import etree
import logging
import threading

BASEPATH = '/home/ubuntu/data/input/'
LOGGING_FILE = '/home/ubuntu/data/log/bad_xml.log'

logger = logging.getLogger('not_good')
logger.setLevel(logging.DEBUG)
ch = logging.StreamHandler()
fh = logging.FileHandler(LOGGING_FILE)
logger.addHandler(fh)
logger.addHandler(ch)

def try_xml(my_f):
    try:
        tree = etree.parse(my_f)
    except Exception as e:
        logger.info(my_f)

# r=root, d=directories, f=files
for r, d, f in os.walk(BASEPATH):
    for file in f:
        if '.kml' in file or '.dae' in file:
            my_f = os.path.join(r, file)
```



```
x = threading.Thread(target=try_xml, args=(my_f,))  
x.daemon = True  
x.start()
```

F.2 EFS auf EC2-Instanz mounten

Anhand einer Anleitung, einem sogenannten Walkthrough, wurde via AWS CLI³⁴ ein EFS an eine EC2-Instanz gemountet und die 3D Daten wurden dorthin kopiert.

Listing 2: EFS auf EC2-Instanz mounten

```
#!/bin/bash
# from https://docs.aws.amazon.com/efs/latest/ug/wt1-create-ec2-resources.html

# security group 4 ec2
aws ec2 create-security-group \
--region eu-west-1 \
--group-name efs-dataprocessing1-ec2-sg \
--description "Amazon EFS dataprocessing 1, SG for EC2 instance" \
--vpc-id vpc-87ad55fe

# security group 4 efs
aws ec2 create-security-group \
--region eu-west-1 \
--group-name efs-dataprocessing1-mt-sg \
--description "Amazon EFS dataprocessing 1, SG for mount target" \
--vpc-id vpc-87ad55fe

# access to ec2 instance group from everywhere
aws ec2 authorize-security-group-ingress \
--group-id sg-098669727548dcedd \
--protocol tcp \
--port 22 \
--cidr 0.0.0.0/0 \
--region eu-west-1

# describe security group
aws ec2 describe-security-groups \
--region eu-west-1 \
--group-id sg-098669727548dcedd

# access to efs storage from ec2 group
aws ec2 authorize-security-group-ingress \
--group-id sg-02778494bc39601d4 \
--protocol tcp \
--port 2049 \
--source-group sg-098669727548dcedd \
--region eu-west-1

# get subnet id
aws ec2 describe-subnets \
--region eu-west-1 \
--filters "Name=vpc-id,Values=vpc-87ad55fe"

# run ec2 instance
aws ec2 run-instances \
--image-id ami-047bb4163c506cd98 \
--count 1 \
--instance-type t2.micro \
--associate-public-ip-address \
--key-name bfh_root.pem \
--security-group-ids sg-098669727548dcedd \
--subnet-id subnet-f66512ac \
--region eu-west-1

aws ec2 describe-instances \
--instance-ids i-09cb26ed64cdde683 \
--region eu-west-1
```

³⁴AWS Command Line Interface: ein kommandozeilenorientiertes Werkzeug

```
# ec2-54-75-53-151.eu-west-1.compute.amazonaws.com
# EFS =====
aws efs create-file-system \
--creation-token FileSystemForDataprocessing1 \
--tags Key=Name,Value=Dataprocessing1 \
--region eu-west-1

# create mount target
aws efs create-mount-target \
--file-system-id fs-5aceld90 \
--subnet-id subnet-f66512ac \
--security-group sg-02778494bc39601d4 \
--region eu-west-1

# On instance amazon linux (ec2-user)
sudo yum -y update
sudo reboot # dont know why... like windows
sudo yum -y install nfs-utils

# On instance ubuntu (ubuntu)
sudo apt-get update
sudo apt-get install nfs-common

mkdir ~/efs-mount-point
cd ~/efs-mount-point
sudo chmod go+rw .

sudo mount -t nfs \
-o nfsvers=4.1,rsize=1048576,wsiz=1048576,hard,timeo=600,retrans=2,noresvport
fs-5aceld90.efs.eu-west-1.amazonaws.com:/ \
~/efs-mount-point

# CP from home to ec2 instance
scp -i bfh_root.pem \
/media/saibot/vortrag/bfh/buildings/*.tar \
ec2-user@54.75.53.151:/home/ec2-user/efs-mount-point/buildings/
```

F.3 Von der SPOT Instanz aus abfragen, was ihr Status ist

Von der Instanz aus können via RESTful API Metadaten der Instanz abgefragt werden. Bezüglich Determinierung einer Spot-Instanz kann der Zustand *none*, *hibernate*, *stop* oder *terminate* sein. *none*, wenn nichts ansteht. Von da an, wo klar ist, dass die Instanz abgestellt werden wird, kann der Zeitpunkt ausgelesen werden.

Listing 3: Status der Instanz abfragen

```
TOKEN=$(curl -X PUT "http://169.254.169.254/latest/api/token" -H  
"X-aws-ec2-metadata-token-ttl-seconds: 21600") && curl -H "X-aws-ec2-metadata-token: $TOKEN"  
http://169.254.169.254/latest/meta-data/instance-action
```

G Für die Semesterarbeit verwendete Software

- ▶ JabRef: Verwaltung des Literaturverzeichnisses (BibTeX).
- ▶ Gummi: LaTeX Editor.
- ▶ AWS CLI: Für das Bereitstellen der AWS Infrastruktur.
- ▶ jq: Für das Filtern von JSON (vor allem von AWS CLI Antworten).
- ▶ git: Versionsmanagement der Textdateien.
- ▶ Google Spreadsheet: Für den Projektplan.